



Universidade Federal de Itajubá
IESTI – Instituto de Engenharia de Sistemas e TI

Marcela Silva Rosa - 2018006527

Mateus Faria Delangélica - 2018015375

Renato Masteguim Neto - 2020001250

Sandy Aniceto da Silva - 2020031527

Projeto Final – IESTI01

**Reconhecimento de Sinais Mioelétricos Individuais de Dedos para Aplicação
em Prótese Biônica**

Itajubá

2021

Projeto Final – IESTI01

Reconhecimento de Sinais Mioelétricos Individuais de Dedos para Aplicação em Prótese Biônica

Relatório referente ao projeto final em grupo realizado ao longo do semestre como requisito parcial para obtenção de aprovação na disciplina de IESTI01, ministrado pelo professor Marcelo Rovai.

INTRODUÇÃO

O seguinte relatório tem o objetivo de detalhar o todo o processo feito pela equipe na realização do projeto de Reconhecimento de Sinais Mioelétricos Individuais de Dedos para Aplicação em Prótese Biônica.

Sendo todos os participantes da equipe membros do projeto de extensão da Universidade Federal de Itajubá - UNIFEI, chamado Ex Machina que, através da tecnologia assistiva trabalha o desenvolvimento de próteses biônicas, surgiu-se a ideia de unir o ideal do projeto com os conhecimentos do curso de TinyML, a fim de evoluir as constantes pesquisas e conceder mais bagagem técnica ao Ex Machina.

Quanto ao desenvolvimento do projeto priorizou-se a organização, com o intuito de evitar confusões ao longo do percurso, visto isso, foi criado um Trello, para organizar os dados coletados do início até o fim. As etapas iniciais foram basicamente a coleta dos dados pelo dataset e para o nosso próprio dataset e algumas etapas também ocorreram simultaneamente, como a fase de testes e tentativas de encaixar o projeto em outros datasets disponibilizados na internet.

DATASETS

Após a definição da base para o projeto final, foi realizada a organização de como seriam coletados os dados que seriam utilizados para treinar o modelo. Inicialmente, o grupo foi mobilizado a fim de verificar a validade tanto de desenvolver datasets autorais, utilizando os sinais captados pelo eletromiógrafo da equipe Ex Machina, quanto de aproveitar possíveis datasets disponíveis de sinais capturados com eletromiógrafos associados a dedos em sites como Kaggle, Google Dataset Search e Know Your Data.

Após o início do trabalho em paralelo das duas ideias citadas anteriormente, foi possível notar que, no caso do uso de datasets externos, apesar de exemplos com dados extremamente relevantes como mostra a figura 01, o sistema utilizado pelos desenvolvedores desses datasets mostrou-se bem divergente do disponível atualmente pela equipe. Mais especificamente, esses sistemas tem uma frequência de amostragem diferente, sinais em amplitudes diferentes (em alguns casos com valores que nem podem ser atingidos por nosso eletromiógrafo) e filtrados de forma diferente do nosso sistema, por isso, foi optado por manter apenas a ideia de desenvolvimento autoral dos datasets e reservar a ideia de uso externo para futuros projetos ou possivelmente testes com transfer learning.

Data set on sEMG and FLEX sensors for finger movement detection or classification

Published: 31 October 2019 | Version 1 | DOI: 10.17632/gb6y2k7358.1

Contributors: Laura Vega-Escobar, Cristian Alzate-Anzola, Juan Botero-Valencia, Juliana Valencia-Aguirre

Description

The database contains the information about the sEMG signals acquired by the eight channels of the Myo Armband device and five Flex sensors located in each one of the hand fingers. There are 54 files in this database in .csv format, one for each subject. The name of the files have the following format: person0X, where X is the number of the subject. Each subject has 14 columns, the first one represents the time in milliseconds (ms), from the second column to the ninth are the signals received from the Myo Armband, and from column tenth to fourteenth are the signals acquired with the Flex sensors. The 8 channels of the Myo Armband were digitized with a sampling frequency of 200 Hz.

Download All 2 MB

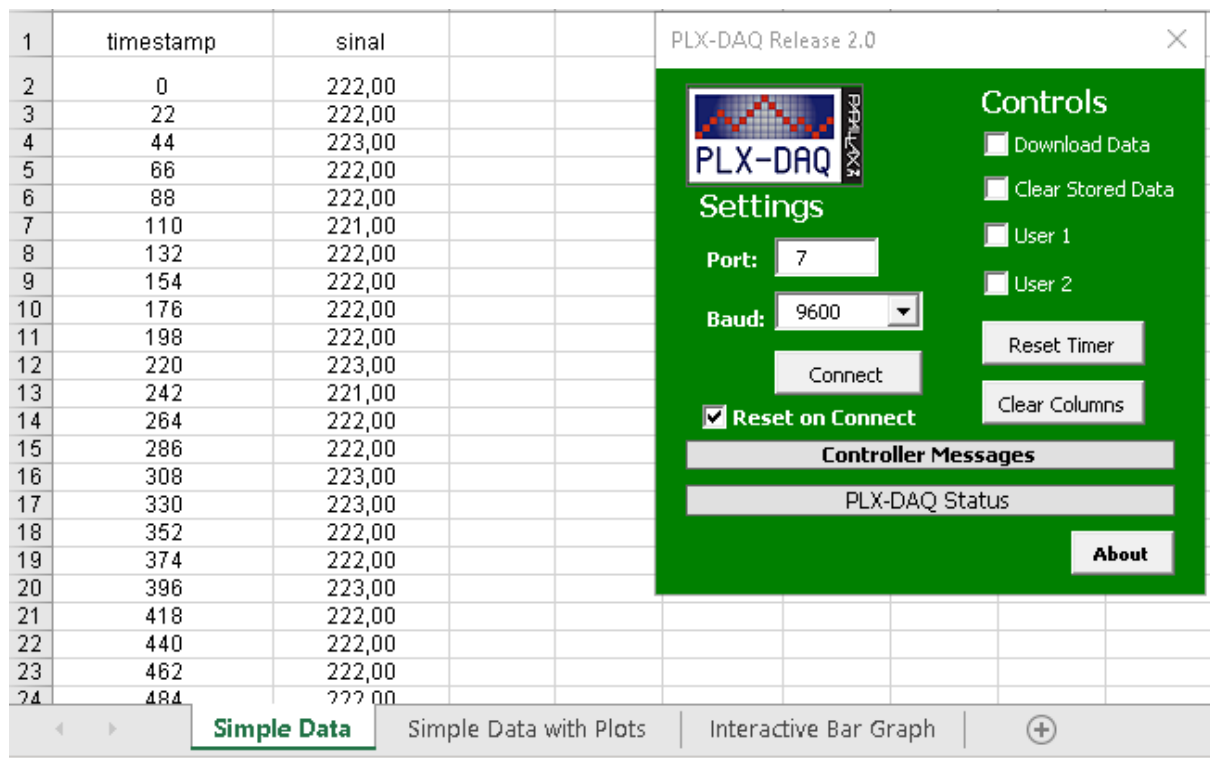
Fonte: <https://data.mendeley.com/datasets/gb6y2k7358/1>, Acesso em: 14/12/2021

Figura 01 – Dataset que Associa Sinais Mioelétricos a Flex Sensors nos Dedos

Vale ressaltar que o eletromiógrafo utilizado pela equipe Ex Machina tem como saída um sinal que varia de 0 a 5V, sendo que a placa que seria utilizada do Arduino Nano 33 BLE Sense suporta apenas 3,3V em suas entradas analógicas, portanto, foram encomendados diodos zener para limitar a tensão de saída e até que eles chegassem foi utilizado o hardware padrão da equipe, um Arduino Nano V3.

Então, foi realizada a primeira coleta de dados, utilizando o eletromiógrafo (EMG) desenvolvido pelo projeto e os sinais captados por 1 canal de 3 eletrodos apenas. Nessa coleta, o sinal de cada um dos dedos foi captado por cerca de 12 minutos e meio (divididos em dados para treino e teste), além disso, foi introduzido um sinal chamado de “nada”, para definir os casos em que o impulso nervoso não estava sendo enviado.

Os dados foram salvos utilizando o software PLX-DAQ e organizados em pastas com cada um dos dedos e divididos em amostras, posteriormente foi realizada a padronização do timestamp, definido com intervalo de 22ms (valor esse que se manteve por todos os dados coletados futuramente também) e a geração do arquivo .csv que será enviado ao site edgeimpulse.com para o restante do desenvolvimento.



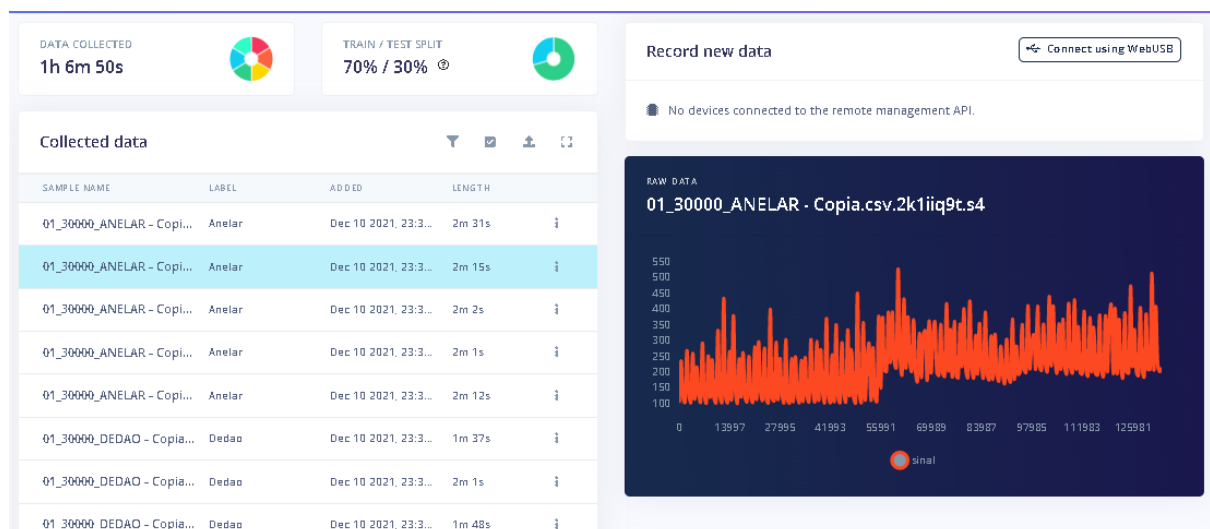
Fonte: elaborado pelos autores.

Figura 02 – PLX-DAQ, 1 Canal de Captação

Nome	Data de modificação	Tipo	Tamanho
Anelar	17/11/2021 08:52	Pasta de arquivos	
Dedao	10/11/2021 08:58	Pasta de arquivos	
Indicador	10/11/2021 08:11	Pasta de arquivos	
Medio	10/11/2021 08:55	Pasta de arquivos	
Mindinho	10/11/2021 08:58	Pasta de arquivos	
Como Coletar Dados com PLX-DAQ.txt	10/11/2021 08:57	Documento de Te...	1 KB

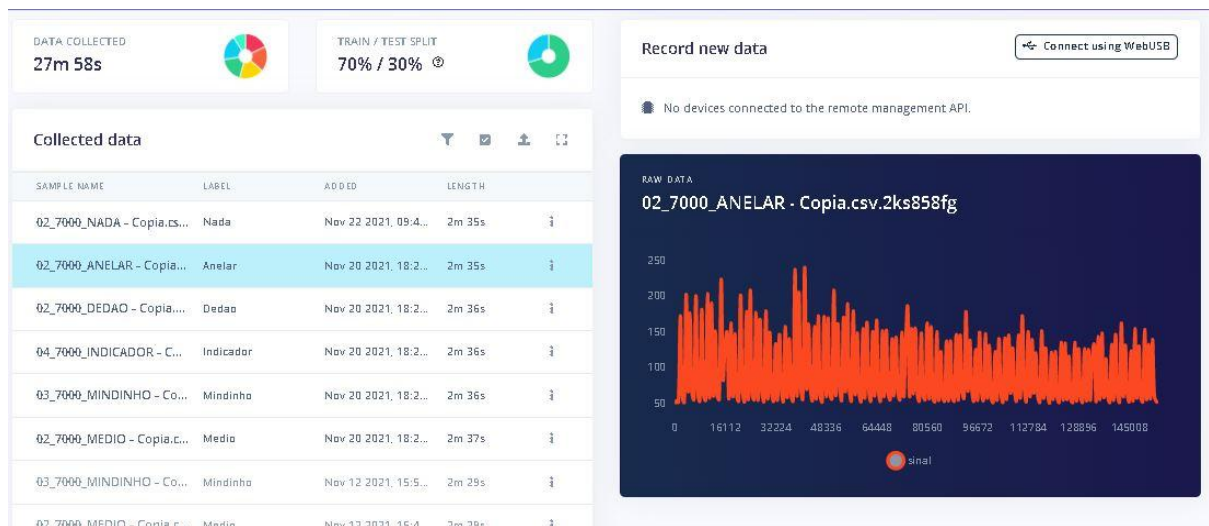
Fonte: elaborado pelos autores.

Figura 03 – Organização dos Dados



Fonte: elaborado pelos autores.

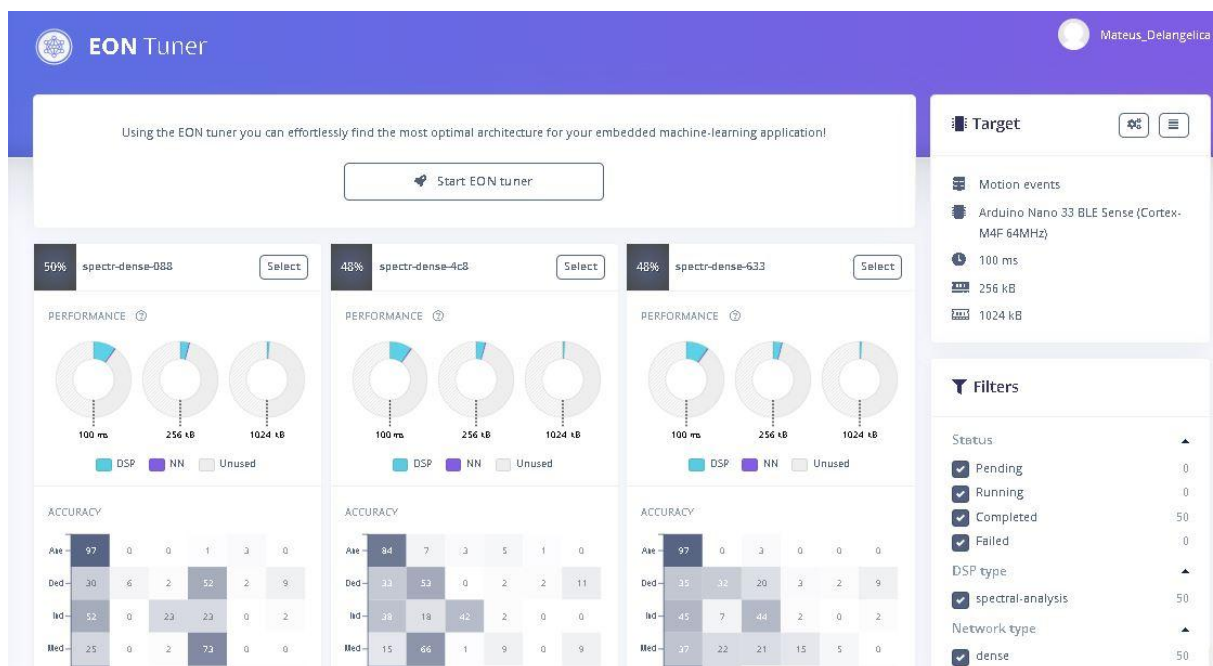
Figura 04 – Dados de Treino



Fonte: elaborado pelos autores.

Figura 05 – Dados de Teste


Esses e todos os outros dados coletados posteriormente foram divididos em ao menos 5 partes para que uma funcionalidade do Edge Impulse chamada EON Tuner pudesse ser utilizada, a fim de otimizar tempo e desempenho no desenvolvimento.



Fonte: elaborado pelos autores.


Figura 06 – EON Tuner

Então, visto que um volume e uma qualidade maior de dados seria necessária, foi desenvolvida uma segunda abordagem, ainda utilizando o hardware padrão da equipe, porém dessa vez utilizando dois módulos EMG, fazendo assim, dois canais de captação com 3 eletrodos cada.



Fonte: elaborado pelos autores.

Figura 07 – Placa de Controle com 2 Módulos EMG



Fonte: elaborado pelos autores.

Figura 08 – Captação com 2 canais

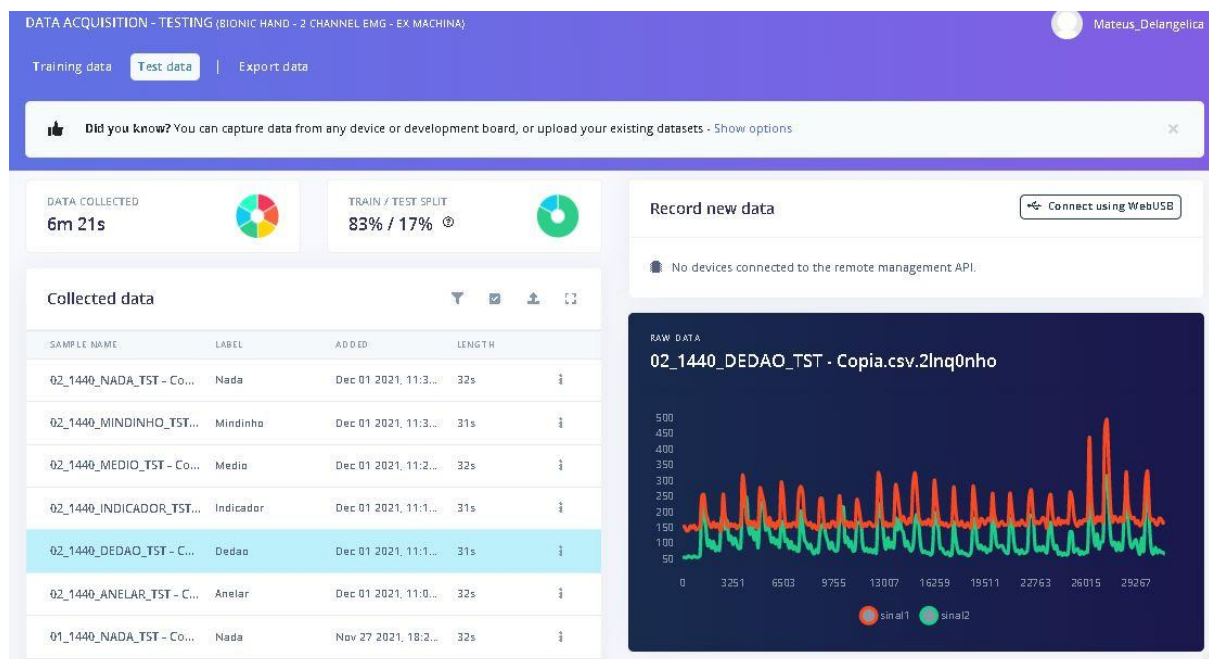
Nesse caso, foram coletados cerca de 6 minutos de dados por dedo, com o mesmo volume de informação para a classe “nada”, esse conteúdo foi dividido entre

teste e treino da mesma forma que havia sido realizado com a versão de 1 canal. O software do PLX-DAQ e o EON Tuner foram utilizados também de forma análoga.



Fonte: elaborado pelos autores.

Figura 09 – Dados de Treino com 2 canais

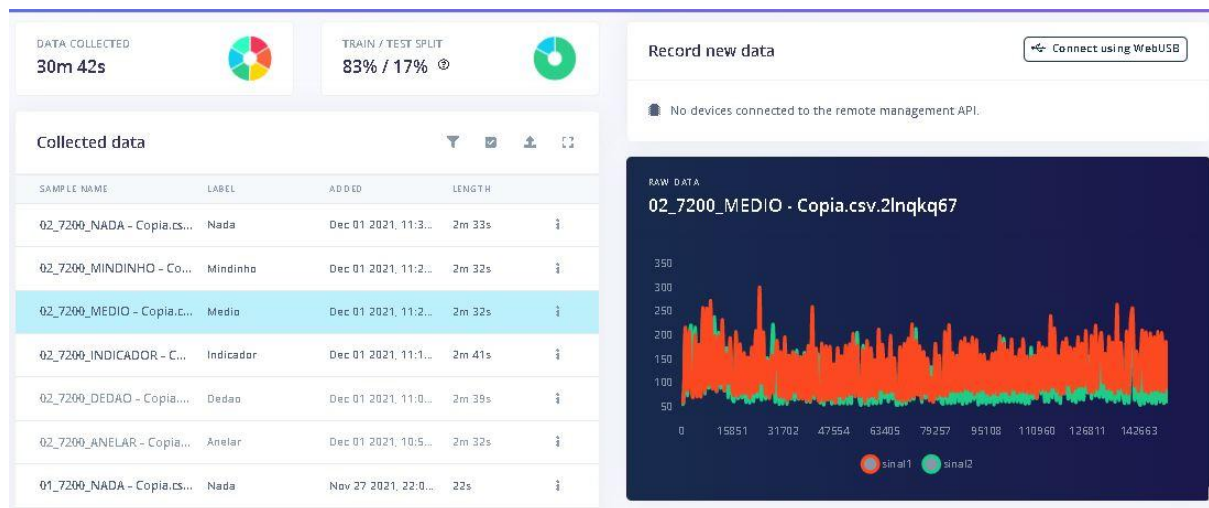


Fonte: elaborado pelos autores.

Figura 10 – Dados de Teste com 2 canais

Levando em consideração que a redução na quantidade de dedos para diferenciar poderia auxiliar na acurácia dos resultados, ainda utilizado os mesmos dados coletados pelo sistema com 2 canais de captação, foram realizados testes de eficácia utilizando 3 dedos apenas.

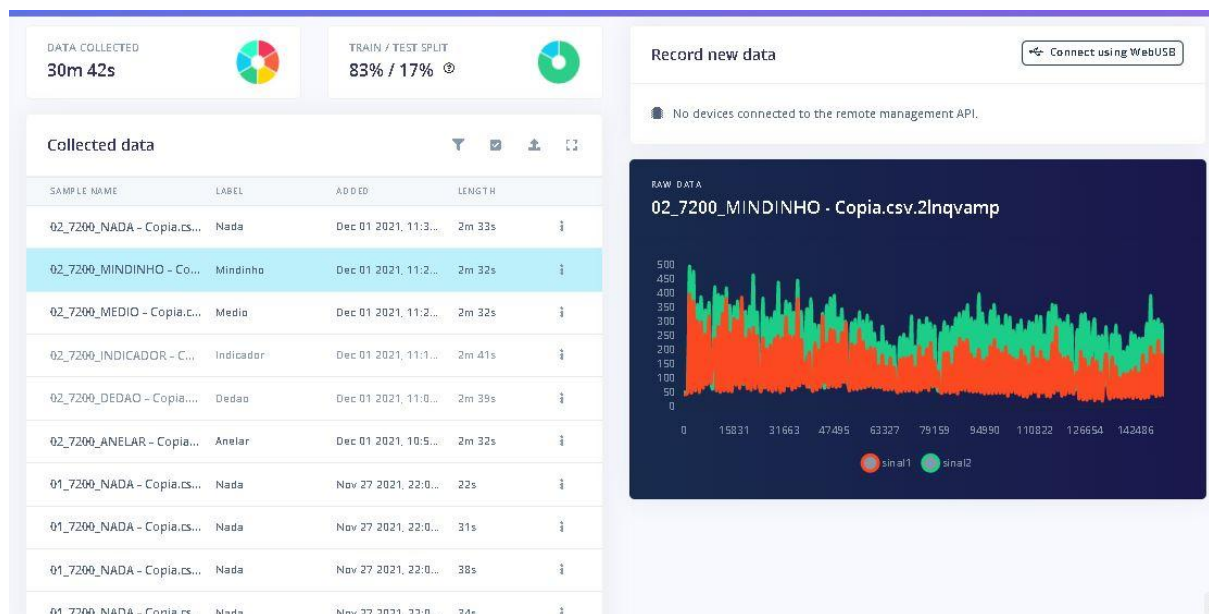
O primeiro teste foi feito selecionando apenas os dados do dedo mindinho, do dedo indicador e do dedo médio, além da classe “nada”, para realizar essa seleção foi necessário apenas desabilitar o restante dos dados coletados e prosseguir com o desenvolvimento.



Fonte: elaborado pelos autores.

Figura 11 – Teste 1

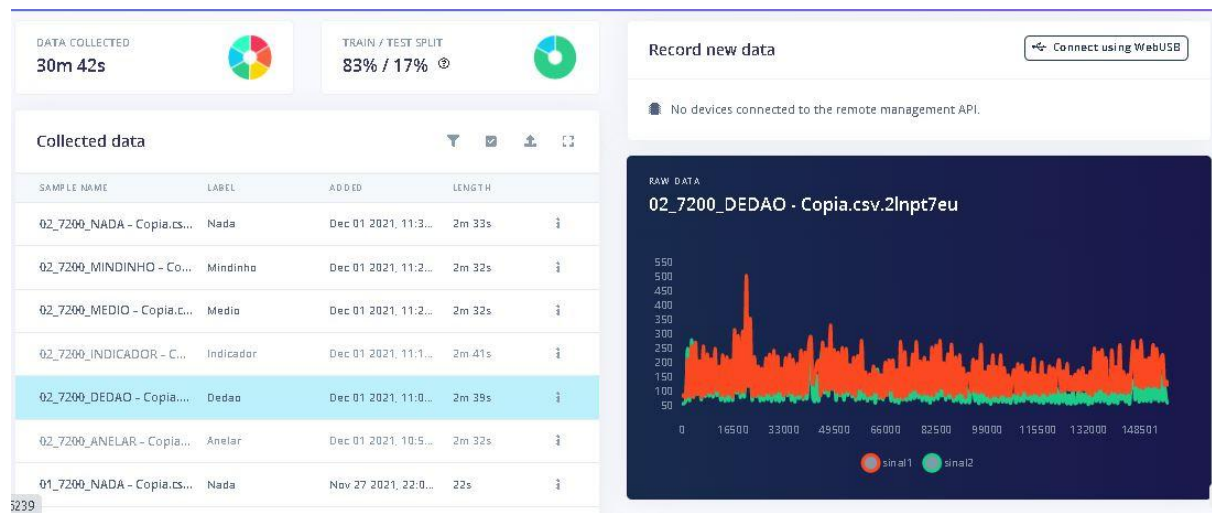
O segundo teste, feito da mesma forma, utilizou apenas os dedos anelar, médio e mindinho.



Fonte: elaborado pelos autores.

Figura 12 – Teste 2


E o terceiro teste usou o dedão, o dedo médio e o mindinho apenas.



Fonte: elaborado pelos autores.

Figura 13 – Teste 3

Ainda a fim de atingir uma acurácia maior e em posse dos diodos zener, foi então inserido o Arduino Nano 33 BLE Sense no sistema, de forma que com ele seria possível realizar a captação dos sinais com uma frequência de amostragem muito maior, além de ser o hardware que seria utilizado para o deploy do modelo após todo o desenvolvimento.




Fonte: elaborado pelos autores.

Figura 14 – Teste de Uso - Arduino Nano 33 BLE Sense


Notou-se que a captação dos sinais pelas portas analógicas do Arduino Nano 33 BLE Sense foi relativamente problemática, visto que ocasionalmente apresentava erros relacionados à porta serial e, até o último teste realizado, seus dados eram impedidos de ser plotados utilizando o software do PLX-DAQ (programa “crasha” antes que os dados do serial sejam registrados). Dessa forma, até o último registro, não foi possível utilizar a placa de desenvolvimento principal na captura dos dados para nosso dataset.

Assim, como alternativa para conseguir uma acurácia maior, o próximo passo foi o desenvolvimento de um terceiro EMG, com um terceiro canal de captação associado.



Fonte: elaborado pelos autores.

Figura 15 – Placa de Controle com 3 Módulos EMG




Fonte: elaborado pelos autores.

Figura 16 – Captação com 3 canais

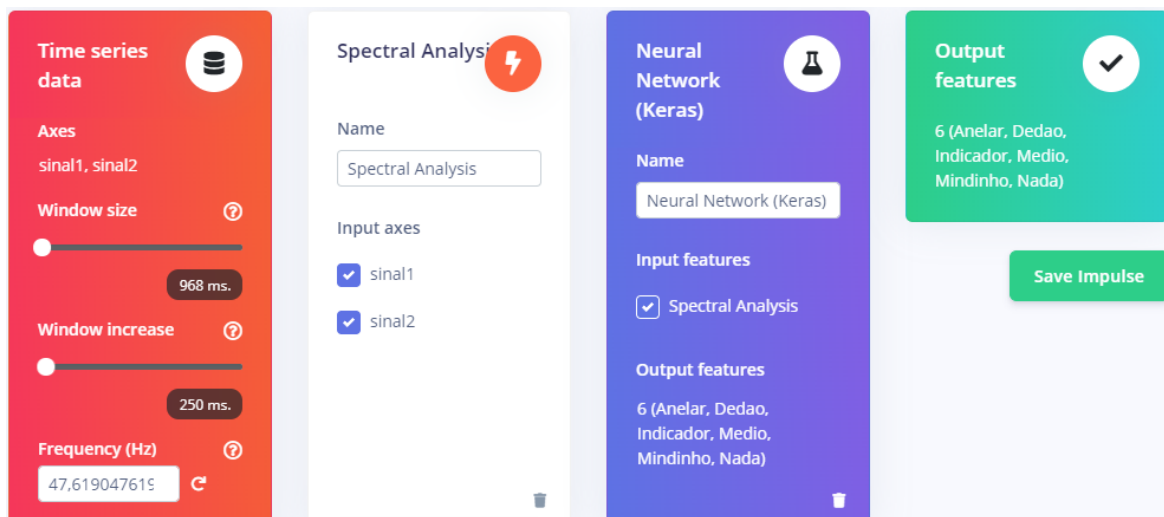
Nesse caso, apesar de promissor, o sistema com 3 EMGs trabalhando de forma conjunta apresentou uma quantidade considerável de falhas, relacionadas aos próprios eletromiógrafos e também à forma como estão dispostos na placa de controle, fazendo com que o sinal de um canal acabe influenciando no outro. Instabilidades foram apresentadas no terceiro canal além disso, fazendo com que os detalhes de parte do sinal fossem perdidos, tornando necessária uma revisão completa nas placas, a qual ainda não apontou nenhum resultado considerável.

Vale ressaltar que os resultados obtidos ao longo do desenvolvimento do projeto final e principalmente nessa etapa de testes com 3 canais, motivaram que mais PCIs (placas de circuito impresso) relacionadas ao uso de IA para próximos trabalhos fossem desenvolvidas pela subequipe de eletrônica da equipe. Essas placas entraram no pedido para produção anual e já foram enviadas à TEC-CI (empresa que confecciona PCIs e patrocina o Ex Machina).



Fonte: elaborado pelos autores.

Figura 17 – Produção Anual - Versão 3D



Fonte: elaborado pelos autores.

Figura 19 – Blocos utilizados no design do modelo

Com os primeiros modelos testados, pretendia-se a classificação entre 6 classes de saída, sendo as 5 primeiras cada um dos dedos e a última, denominada “nada”, representando nenhum movimento dos dedos.

Diversos testes foram realizados pelos membros da equipe buscando um valor que fosse o mais próximo possível de pelo menos uns 80% de *Accuracy*. Variou-se parâmetros desde o número de pontos FFT da análise espectral, ao tipo de filtro aplicado aos sinais do dataset. Também foram testadas diversas configurações para a rede neural, adicionando e removendo *hidden layers* do tipo “*Dense*” e “*Dropout*”, ou ainda modificando somente as quantidades de neurônios em cada *layer Dense*. A quantidade de épocas para o treinamento do modelo também foi explorada e apesar de uma melhora no modelo após a adição do segundo canal de captação, os resultados obtidos ainda eram insatisfatórios.

Neural network architecture



Fonte: elaborado pelos autores.

Figura 20 – Exemplo de rede neural testada para os dados de 1 canal de captação

Training settings

Number of training cycles ?

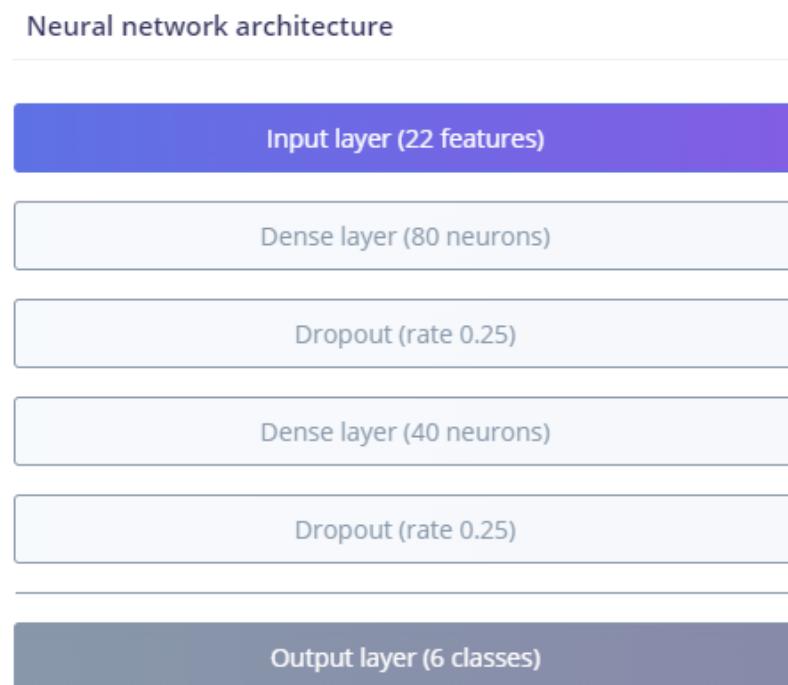
150

Learning rate ?

0.0005

Fonte: elaborado pelos autores.

Figura 21 – Exemplo de configuração utilizada para o treinamento com dados de 1 canal de captação



Fonte: elaborado pelos autores.

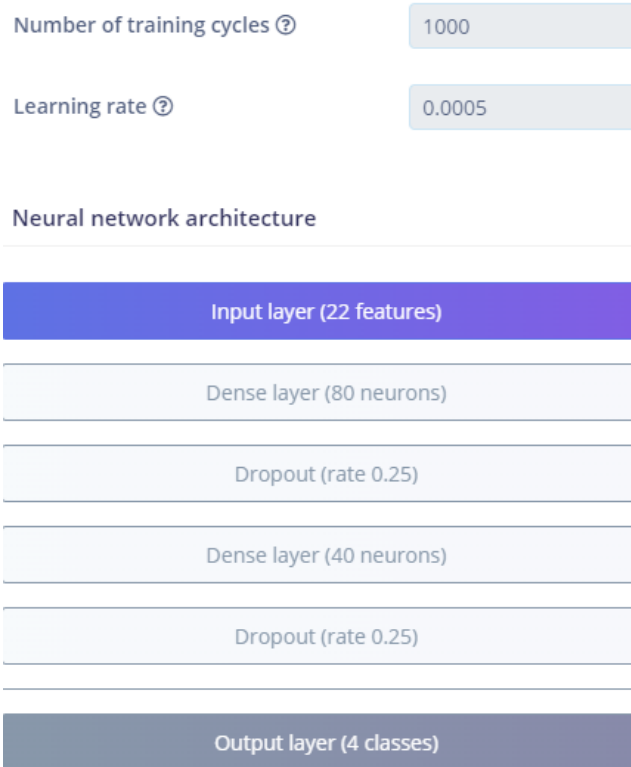
Figura 22 – Exemplo de rede neural testada para dados de 2 canais de captação

Number of training cycles ?	100
Learning rate ?	0.0005

Fonte: elaborado pelos autores.

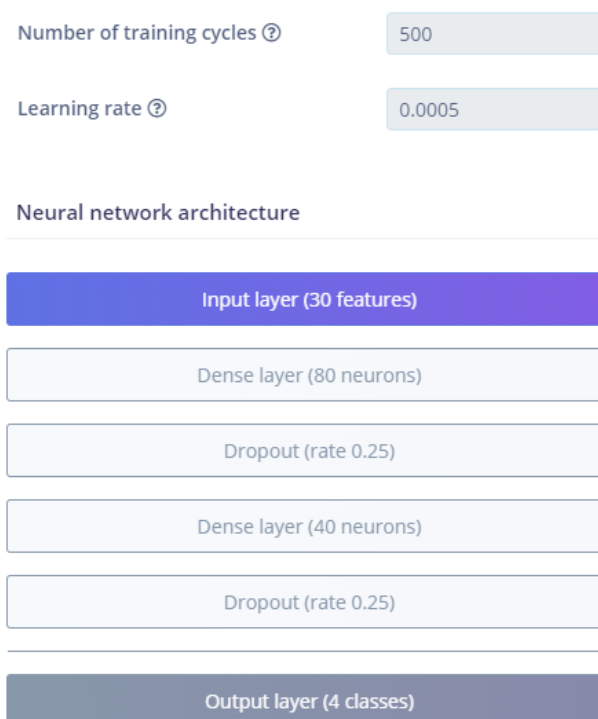
Figura 23 – Exemplo de configuração utilizada para o treinamento com dados de 2 canais de captação

Com isso, foi decidido mudar a abordagem inicial e passou-se a treinar modelos com o objetivo de classificação entre apenas 4 classes, sendo elas uma classe para cada um dos 3 dedos selecionados e a classe “nada”. O mesmo processo de testes realizados com o modelos anteriores foram realizados para estes novos modelos com 4 classes de saída. Assim, obteve-se, finalmente, resultados mais próximos do desejado. As arquiteturas de rede neural e configurações de treinamento para esses modelos podem ser observados nas figuras abaixo.



Fonte: elaborado pelos autores.

Figura 24 – Modelo utilizado na classificação de dois conjuntos de 3 dedos (anelar, médio, mindinho e indicador, médio, mindinho)



Fonte: elaborado pelos autores.

Figura 25 – Modelo utilizado na classificação do último conjunto de 3 dedos (Dedão, médio, mindinho)

RESULTADOS E DISCUSSÕES

A ideia deste projeto em questão foi de utilizar Machine Learning para aprimorar a utilização da prótese biônica do projeto especial Ex Machina, da Unifei, tentando fazer com que ela aprendesse a diferenciar cada dedo a partir de um impulso nervoso.

Com os dados captados utilizando o Arduino Nano v3, conseguimos montar um pequeno dataset baseado nos impulsos nervosos de Mateus Faria Delangelica (membro do projeto), pois ele quem estava em posse da prótese, devido ao modo de ensino remoto vivido atualmente. Com isso, todas as respostas de treinamento obtidas foram baseados no dataset coletado.

Para o EMG com apenas um canal de captação obtivemos uma baixa precisão e a diferenciação ficou confusa devido aos dados possuírem frequências muito parecidas, os resultados obtidos estão presentes na figura 26 e seu teste utilizando os dados separados para isso estão presentes na figura 27.



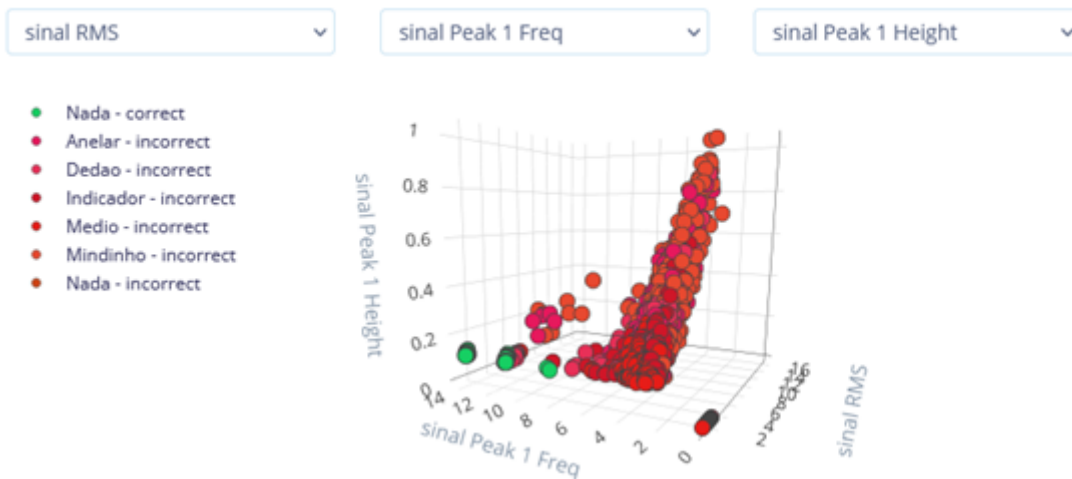
Fonte: elaborado pelos autores.

Figura 26 – Treinamento utilizando todos os dedos com 1 canal de captação.

ACCURACY
16.34%

	ANELAR	DEDAO	INDICADOR	MEDIO	MINDINHO	NADA	UNCERTAIN
ANELAR	0%	0%	0%	0%	0%	0%	100%
DEDAO	0%	0%	0%	0.3%	0%	2.5%	97.2%
INDICADOR	0%	0%	0%	0%	0%	0.3%	99.7%
MEDIO	0%	0%	0%	0%	0%	8.4%	91.6%
MINDINHO	0.3%	0%	0%	0%	0%	0%	99.7%
NADA	0%	0%	0%	0%	0%	98.7%	1.3%
F1 SCORE	0.00	0.00	0.00	0.00	0.00	0.94	

Feature explorer ?



Fonte: elaborado pelos autores.

Figura 27 – Teste utilizando todos os dedos com 1 canal de captação.

Com isso, foi necessário aprimorar o EMG, adicionando outro canal de captação. Assim com 2 canais de captação conseguimos alguns resultados melhores, como pode ser visto na figura 28 e na figura 29.

Last training performance (validation set)

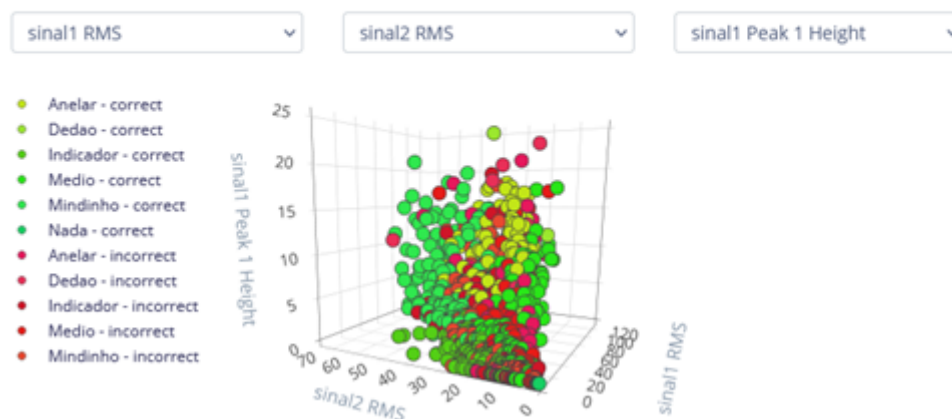
ACCURACY
67.4%

LOSS
0,89

Confusion matrix (validation set)

	ANELAR	DEDAO	INDICADOR	MEDIO	MINDINHO	NADA
ANELAR	70.9%	6.2%	8.7%	8%	6.2%	0%
DEDAO	17.8%	61.9%	3.3%	11.9%	4.8%	0.4%
INDICADOR	21.0%	6.6%	59.5%	1.6%	11.3%	0%
MEDIO	11.0%	26.0%	4.7%	57.5%	0.4%	0.4%
MINDINHO	19.6%	2.6%	18.5%	3.0%	56.2%	0%
NADA	0%	0%	0%	0%	0%	100%
F1 SCORE	0.60	0.61	0.61	0.63	0.63	1.00

Feature explorer (full training set) ?



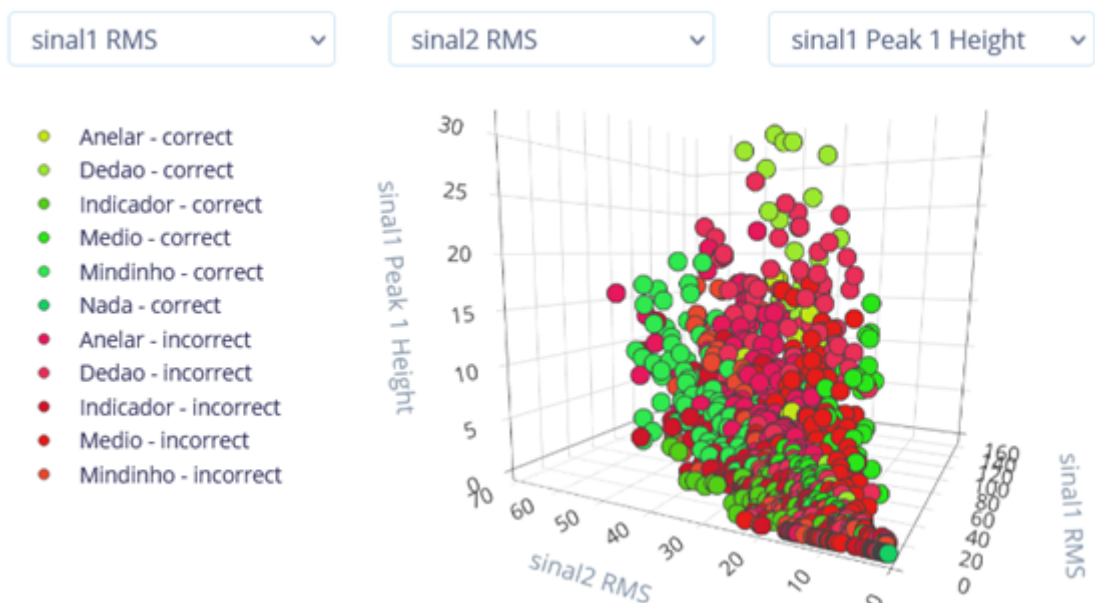
Fonte: elaborado pelos autores.

Figura 28 – Treinamento utilizando todos os dedos com 2 canais de captação.

% ACCURACY
37.98%

	ANELAR	DEDAO	INDICADOR	MEDIO	MINDINHO	NADA	UNCERTAIN
ANELAR	5.7%	1.9%	1.1%	5.7%	5.7%	0%	79.9%
DEDAO	9.0%	10.2%	2.3%	19.9%	3.4%	0.4%	54.9%
INDICADOR	1.1%	0.4%	18.7%	3.4%	14.2%	0.4%	61.8%
MEDIO	6.3%	3.3%	1.5%	42.8%	0%	0%	46.1%
MINDINHO	0.4%	0%	3.3%	0.7%	49.1%	0.4%	46.1%
NADA	0%	0%	0%	0%	0%	100%	0%
F1 SCORE	0.09	0.18	0.29	0.50	0.57	0.99	

Feature explorer ?



Fonte: elaborado pelos autores.

Figura 29– Teste utilizando todos os dedos com 2 canais de captação.

Então por recomendação do professor, diminuimos a quantidade de dedos a serem treinados devido a indisponibilidade de se ter mais de 2 canais, devido a problemas com componentes, não foi possível montar outro EMG para ser o terceiro canal.

Assim, foram elaborados mais 3 modelos, e os resultados do treinamento com 2 canais utilizando apenas 3 dedos se encontram nas figuras abaixo.

Na figura 30 está presente o treinamento do primeiro modelo e na figura 31 está presente o teste desse modelo, e como pode ser observado há uma enorme evolução nos resultados.

Last training performance (validation set)



ACCURACY

72.1%



LOSS

2,17

Confusion matrix (validation set)

	INDICADOR	MEDIO	MINDINHO	NADA
INDICADOR	86.8%	2.3%	10.9%	0%
MEDIO	41.4%	54.1%	4.1%	0.4%
MINDINHO	49.7%	0.3%	50%	0%
NADA	0%	0%	0%	100%
F1 SCORE	0.61	0.69	0.61	1.00


Feature explorer (full training set) ?

sinal1 RMS ▾

sinal2 RMS ▾

sinal1 Peak 1 Height ▾

- Indicador - correct
- Medio - correct
- Mindinho - correct
- Nada - correct
- Indicador - incorrect
- Medio - incorrect
- Mindinho - incorrect



Fonte: elaborado pelos autores.

Figura 30 – Treinamento do modelo 1 utilizando 3 dedos com 2 canais de captação.



ACCURACY
78.07%

	INDICADOR	MEDIO	MINDINHO	NADA	UNCERTAIN
INDICADOR	44.2%	5.2%	27.7%	0.7%	22.1%
MEDIO	3.0%	88.5%	2.2%	0.4%	5.9%
MINDINHO	6.7%	1.1%	79.2%	0.7%	12.3%
NADA	0%	0%	0%	100%	0%
F1 SCORE	0.57	0.91	0.76	0.99	

Feature explorer ?

sinal1 RMS




sinal2 RMS



sinal1 Peak 1 Height



- Indicador - correct
- Medio - correct
- Mindinho - correct
- Nada - correct
- Indicador - incorrect
- Medio - incorrect
- Mindinho - incorrect



Fonte: elaborado pelos autores.

Figura 31 – Teste do modelo 1 utilizando 3 dedos com 2 canais de captação.

Em seguida elaboramos um segundo modelo, cujo treinamento está presente na figura 32 e seu teste na figura 33.

Last training performance (validation set)



ACCURACY

80.8%



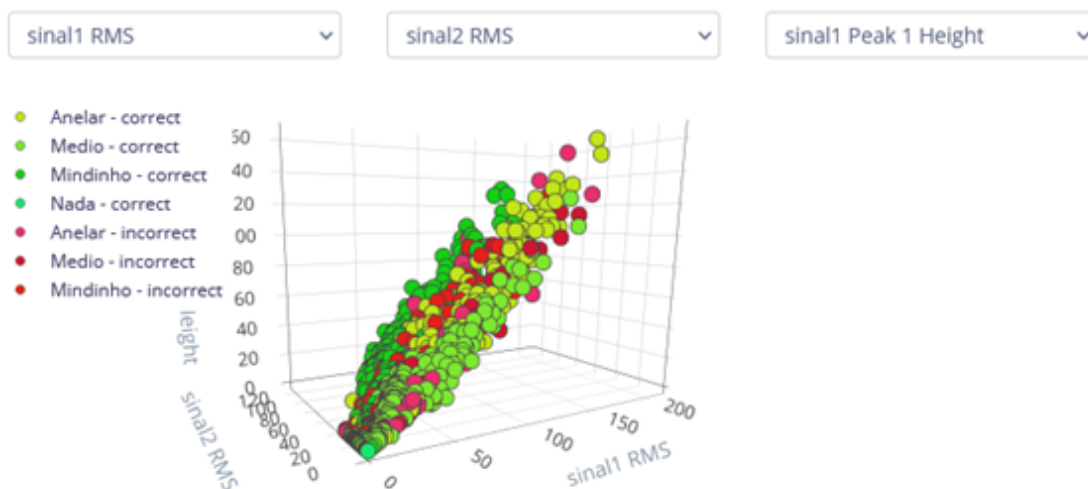
LOSS

0,47

Confusion matrix (validation set)

	ANELAR	MEDIO	MINDINHO	NADA
ANELAR	81.5%	10.0%	8.4%	0%
MEDIO	20.7%	78.1%	1.2%	0%
MINDINHO	32.5%	4.5%	63.0%	0%
NADA	0%	0%	0%	100%
F1 SCORE	0.69	0.81	0.73	1.00

Feature explorer (full training set) ?



Fonte: elaborado pelos autores.

Figura 32 – Treinamento do modelo 2 utilizando 3 dedos com 2 canais de captação.

Houveram alguns problemas com o Arduino BLE Sense, o que impossibilitou que o fizéssemos o deploy para testar na prática, mas como já havia sido discutido em aula com o professor, esse projeto será continuado para além da disciplina, afim de que o projeto Ex Machina possa prosseguir com seus desenvolvimentos.



ACCURACY
67.10%

	ANELAR	MEDIO	MINDINHO	NADA	UNCERTAIN
ANELAR	28.8%	21.2%	14.0%	1.1%	34.8%
MEDIO	11.5%	77.7%	1.5%	1.1%	8.2%
MINDINHO	10.8%	3.7%	61.0%	0.7%	23.8%
NADA	0%	0%	0%	100%	0%
F1 SCORE	0.38	0.77	0.69	0.99	

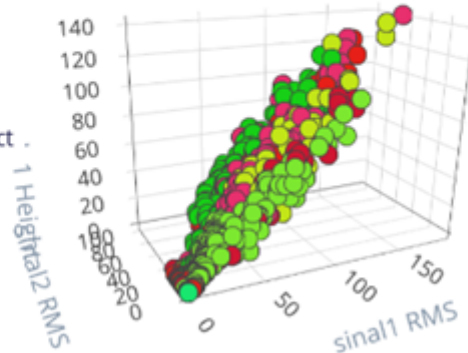
Feature explorer

senal1 RMS

senal2 RMS

senal1 Peak 1 Height

- Anelar - correct
- Medio - correct
- Mindinho - correct
- Nada - correct
- Anelar - incorrect
- Medio - incorrect
- Mindinho - incorrect



Fonte: elaborado pelos autores.

Figura 33 – Teste do modelo 2 utilizando 3 dedos com 2 canais de captação.

Por fim, foi elaborado um terceiro modelo com 2 canais e 3 dedos, cujo treinamento está na figura 34 e os testes na figura 35

Last training performance (validation set)



ACCURACY

76.1%



LOSS

1,02

Confusion matrix (validation set)

	DEDAO	MEDIO	MINDINHO	NADA
DEDAO	73.0%	17.9%	6.8%	2.3%
MEDIO	51.4%	46.2%	1.6%	0.8%
MINDINHO	11.3%	4.2%	84.5%	0%
NADA	0%	0%	0%	100%
F1 SCORE	0.62	0.54	0.88	0.98

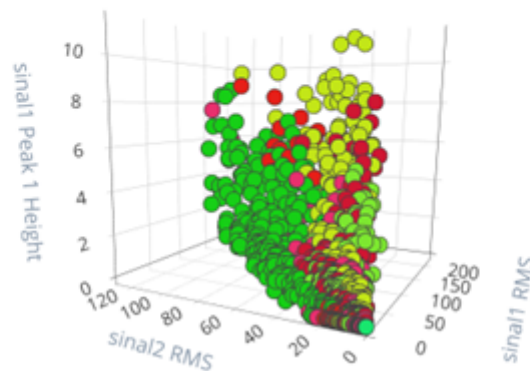
Feature explorer (full training set) ?

sinal1 RMS ▾

sinal2 RMS ▾

sinal1 Peak 1 Height ▾

- Dedao - correct
- Medio - correct
- Mindinho - correct
- Nada - correct
- Dedao - incorrect
- Medio - incorrect
- Mindinho - incorrect



Fonte: elaborado pelos autores.

Figura 34 – Treinamento do modelo 3 utilizando 3 dedos com 2 canais de captação.



ACCURACY

72.47%

	DEDAO	MEDIO	MINDINHO	NADA	UNCERTAIN
DEDAO	30.8%	29.7%	18.8%	0.4%	20.3%
MEDIO	9.3%	69.1%	4.8%	0%	16.7%
MINDINHO	1.1%	1.9%	89.2%	0%	7.8%
NADA	0%	0%	0%	100%	0%
F1 SCORE	0.44	0.69	0.84	1.00	

Feature explorer ?

sinal1 RMS




sinal2 RMS



sinal1 Peak 1 Heigh



- Dedao - correct
- Medio - correct
- Mindinho - correct
- Nada - correct
- Dedao - incorrect
- Medio - incorrect
- Mindinho - incorrect



Fonte: elaborado pelos autores.

Figura 35 – Teste do modelo 3 utilizando 3 dedos com 2 canais de captação.

Analisando os 3 modelos que utilizam 2 canais para 3 dedos, pode-se observar que:

O modelo 1 é curioso notar que a precisão dos testes foi maior que a precisão dos treinos, o que torna o modelo inconsistente.

O modelo 2 apresenta uma alta precisão de treinos, porém é um pouco baixa a precisão de testes.

O modelo 3 é o mais consistente, pois apresentou precisões parecidas para o treinamento e para o teste, sendo assim, pode ser considerado o melhor dentre os modelos.

CONCLUSÃO

O que pode ser concluído desse projeto é que, com mais canais de captação conseguiremos mais resultados, e o Ex Machina já está trabalhando para implementar novos canais de captação com novas placas de circuito para que assim sejam feitos testes.

Captar os dados com o Arduino BLE Sense também será um dos próximos objetivos, para que se possa tirar conclusões a respeito do melhor dispositivo para ser utilizado no objetivo do projeto.

Também notamos que pode ser possível realizar com êxito a diferenciação dedo a dedo de uma prótese biônica utilizando TinyML, mas ainda é necessário expandir os datasets e os canais de captação dos impulsos nervosos. O fato de ser possível a implantação será importante na busca pela ampliação da tecnologia assistiva, que é o foco do Ex Machina, utilizando I.A. com responsabilidade e seriedade