

IESTI01 – TinyML - 2021.2

Final Group Project Proposal

1. Project name

Machine Learning para reconhecimento de dígitos em medidores de consumo de energia analógico e digital.

2. Team member names, number (if applicable) and, Institution

Carlos Eduardo Gomes - IFSP

Carlos Eduardo Oliveira Silva -IFSP

Ivan Lucas Arantes - IFSP

Matheus Mascarenhas - IFSP

3. Project Objectives (Goal) -

Reconhecimento de dígitos de medidores de energia residencial e comercial, de imagens capturadas por câmeras digitais, para emissão de fatura de consumo de energia mensal .

4. Longer project description

A leitura de medidores de energia elétrica pode ser realizada de forma mais rápida e eficiente se automatizada quando comparada à leitura manual. O objetivo é utilizar imagens (fotos) de medidores, sejam os medidores inteligentes ou os modelos antigos (analógicos) para a leitura do consumo de energia elétrica da unidade consumidora, buscando a redução de custos considerando o aumento do volume de coletas dos dados de faturamento no mesmo período de trabalho do coletador. O fator complicador aqui se dá ao fato que medidores possuem formatos diferentes (digitais e analógicos) e as características das imagens tiradas com posicionamento da câmera pelo operador e da resolução utilizada. O aprendizado de máquina deverá ser capaz de “entender” o tipo do medidor e o posicionamento da informação relevante a ser informada. Uma preocupação adicional é que cada unidade consumidora possui um código, que no caso de medidores modernos poderá ser lido de um código de barras, mas para os medidores analógicos é um número que deverá ser aprendido também. Com relação à base de dados para treinamento e pré-teste, já existe uma disponível, denominada UFPR-ADMR Dataset (<https://web.inf.ufpr.br/vri/databases/ufpr-admr/>) principalmente para medidores a dial (ponteiro). Para medidores digitais deverá ser criada ou verificada junto a concessionária de energia elétrica a existência de base pronta.

O desafio do projeto será o reconhecimento do display digital ou ponteiros e a identificação do tipo de medidor pelo deep learning , através de aprimoramento da imagem, aplicação de efeitos para as aparências do display digital no que tange os diferentes ângulos de foto, bem como a interferência do ambiente, melhorando assim a adaptabilidade do método de aprendizagem.

5. References (including other code or data), sources of inspiration

KASAR, Thotreingam. Recognition of Seven-Segment Displays from Images of Digital Energy Meters. Data Analytics And Learning, [S.L.], p. 1-10, 5 nov. 2018. Springer Singapore. http://dx.doi.org/10.1007/978-981-13-2514-4_1.

Hong Shuo, Yu Ximing, et.all Digital recognition of electric meter with deep learning.14th IEEE International Conference on Electronic Measurement & Instruments.

G. Salomon, R. Laroca, and D. Menotti, "Deep learning for image-based automatic dial meter reading: Dataset and baselines," in International Joint Conference on Neural Networks (IJCNN), July 2020, pp. 1–8.

6. Descriptions of the following, at whatever depth the team feels appropriate:

O projeto pode ser dividido em duas partes. A primeira consiste no desenvolvimento de um modelo através de uma base de dados de imagens de medidores analógicos e digitais, fazendo o treinamento e um pré-teste com as imagens estáticas. A segunda parte do projeto é a implementação do modelo dentro de um hardware composto essencialmente por microcontrolador, câmera e display, fazendo "em tempo real" a inferência dos medidores. Os valores resultantes de energia consumida e código do consumidor serão mostrados em display LCD.

a. Block Diagram

A seguir é mostrado o diagrama de blocos do sistema para a realização da inferência




Fig 1 - Diagrama de blocos do hardware

b. Hardware to be utilized

O hardware a ser desenvolvido, conforme fig 1, terá os seguintes componentes principais:

b.1- Sistema embarcado: Placa Arduino Nano 33 BLE Sense ou ESP-32CAM (a depender da disponibilidade) com microcontrolador que irá realizar o tratamento da imagem e “rodar” o modelo desenvolvido, de forma a identificar o consumo de energia.

b.2- Câmera: Utilizada para fazer a aquisição da imagem do medidor de energia

b.3- Display: Mostrar os valores de saída resultantes

c. Data collection

Conforme mencionado anteriormente, o dataset será um banco de imagens de medidores analógicos e digitais utilizados para o treinamento e alguns testes, além de um pequeno banco próprio complementar para averiguação dos resultados.

d. Preprocessing

As imagens serão processadas de maneira a formatá-las em uma mesma dimensão, fazer a normalização e se necessário passar por tratamento utilizando alguns filtros. Além disto será aplicado técnicas de transfer learning para pré-aprendizagem de leituras de números e códigos de barras.

e. Model design

A princípio o modelo a ser criado é do tipo CNN com várias camadas de convolução, maxpooling e DNN no final. O modelo terá que identificar os ponteiros ou o mostrador digital e depois para cada dígito realizar a classificação. Assim sua saída terá 10 (probabilidades) das classes (0 a 9), isto para cada dígito (n). Portanto, a última camada terá um total de $(10 \times n)$ neurônios. Estas saídas passarão por um pós-processamento e computado o valor de energia gasta na forma de um valor do tipo real (“float”).

f. Optimizations

Para otimização, serão utilizadas as funções SGD (Stochastic Gradient Descent) e Adam, tendo em vista a obtenção da melhor *accuracy* possível para a rede neural.

g. In system inference (Deploy)

Após o desenvolvimento e validação em computador, usando *Python* e todos os pacotes de *Machine Learning*, o modelo será então convertido usando a ferramenta *TensorFlow Lite Micro*. A conversão irá transformar o modelo em uma forma reduzida e a princípio em linguagem C compatível com o hardware escolhido. Após esta conversão deve-se fazer a readequação e realização dos testes de inferência em medidores reais.

7. Issues or roadblocks the team envision and potential solutions

- Encontrar um data set adequado: Já estão sendo buscados os bancos de imagens, além de analisado como se incrementar os mesmos com imagens próprias.
- Testes de inferência em medidores reais: Para a realização dos testes iniciais no hardware, deverá ser possível analisar as imagens e os resultados capturados da câmera para conseguir averiguar os erros. Portanto, será feito uma aplicação capaz de salvar ou enviar as mesmas para um computador.
- Claridade nos medidores reais: Poderá ser necessário o uso de uma lanterna caso as imagens capturadas pela câmera estejam com pouco contraste.

8. The top unresolved question(s) the team have at this point

- Diferentes tipos de medidores (variação de tipos de números e ponteiros): Um questionamento é se realmente será possível com um mesmo modelo identificar todos os tipos de medidores



Ponteiros

Ciclométrico

Digital

Fig.2 Tipos de medidores

- Não se sabe a quantidade de camadas convolucionais, de redes neurais e o número de neurônios nas camadas intermediárias.